

NLP Home Tasks

Name:- Muhammad Hassan Khalid

Roll Number:- 21L-5692

Section:- BOS-6B

This = 0.31 0.22 0.99 0.04

is = 0.21 0.42 0.09 0.06

my = 0.72 0.41 0.30 0.39

first = 0.51 0.31 0.87 0.78

embedding = 0.62 0.73 0.11 0.12

computation = 0.72 0.11 0.14 0.15

Weights W_1, W_2, W_3, W_4, W_0 are provided

$$Q = K = V = X = \begin{bmatrix} 0.31 & 0.22 & 0.99 & 0.04 \\ 0.21 & 0.42 & 0.09 & 0.06 \\ 0.72 & 0.41 & 0.30 & 0.39 \\ 0.51 & 0.31 & 0.87 & 0.78 \\ 0.62 & 0.73 & 0.11 & 0.12 \\ 0.72 & 0.11 & 0.14 & 0.15 \end{bmatrix}$$

Computing Attention Heads and Q_i, K_i, V_i in the following ways:-

$Q_1 = Q \cdot W_1, Q_2 = Q \cdot W_2, Q_3 = Q \cdot W_3$ as each computation will be for K_{1-4} and V_{1-4} .

Then computing heads $H_i = \text{softmax}\left(\frac{Q_i \cdot K_i^T}{\sqrt{d_k}}\right) \cdot V_i$

Then Multihead attention $(Q, K, V) = \text{concat}(H_1, H_2, H_3, H_4), w_b$

Computing Q_1, Q_2, Q_3 and Q_4 by their respective weights

$$Q_1 \cdot w_1 = \begin{bmatrix} 0.31 & 0.22 & 0.99 & 0.04 \\ 0.21 & 0.42 & 0.09 & 0.06 \\ 0.72 & 0.41 & 0.30 & 0.39 \\ 0.51 & 0.31 & 0.87 & 0.78 \\ 0.62 & 0.73 & 0.11 & 0.12 \\ 0.72 & 0.11 & 0.14 & 0.15 \end{bmatrix} \times \begin{bmatrix} 0.8 \\ 0.3 \\ 0.9 \\ 0.6 \end{bmatrix}$$

$$= \begin{bmatrix} 0.31 \times 0.8 + \dots + 0.04 \times 0.6 \\ 0.21 \times 0.8 + \dots + 0.06 \times 0.6 \\ 0.72 \times 0.8 + \dots + 0.39 \times 0.6 \\ 0.51 \times 0.8 + \dots + 0.78 \times 0.6 \\ 0.62 \times 0.8 + \dots + 0.12 \times 0.6 \\ 0.72 \times 0.8 + \dots + 0.15 \times 0.6 \end{bmatrix}$$

$$= \begin{bmatrix} 1.259 \\ 0.411 \\ 1.203 \\ 1.752 \\ 0.886 \\ 0.825 \end{bmatrix} = K_1 = V_1 = Q_1$$

$$H_1 = \text{softmax}\left(\frac{Q_1 \cdot K_1^T}{\sqrt{d_k}}\right) \cdot V_1 \Rightarrow \text{softmax}(Q_1 \cdot K_1^T) \cdot V_1$$

$\therefore d_k = 1 \quad \text{so } \sqrt{1} = 1$

$$Q_1 \times K_1^T = \begin{bmatrix} 1.259 \\ 0.411 \\ 1.203 \\ 1.752 \\ 0.886 \\ 0.825 \end{bmatrix} \begin{bmatrix} 1.259 & 0.411 & 0.203 & 1.752 & 0.886 & 0.825 \end{bmatrix}$$

$$= \begin{bmatrix} 0.016 & 0.051 & 0.15 & 0.22 & 0.11 & 0.103 \\ 0.05 & 0.17 & 0.49 & 0.72 & 0.36 & 0.34 \\ 0.15 & 0.49 & 1.447 & 2.107 & 1.065 & 0.94 \\ 0.22 & 0.72 & 2.107 & 3.064 & 1.53 & 1.44 \\ 0.11 & 0.36 & 1.06 & 1.55 & 0.78 & 0.73 \\ 0.103 & 0.33 & 0.992 & 0.495 & 0.77 & 0.68 \end{bmatrix}$$

Softmax of above matrix

$$= \begin{bmatrix} 0.15 & 0.517 & 0.17 & 0.18 & 0.106 & 0.165 \\ 0.1199 & 0.133 & 0.186 & 0.23 & 0.163 & 0.1603 \\ 0.056 & 0.078 & 0.203 & 0.396 & 0.1399 & 0.129 \\ 0.22 & 0.048 & 0.193 & 0.512 & 0.11 & 0.10 \\ 0.077 & 0.094 & 0.20 & 0.327 & 0.13 & 0.14 \\ 0.13 & 0.275 & 0.159 & 0.22 & 0.22 & 0.21 \end{bmatrix} \times V_1 \begin{bmatrix} 1.259 \\ 0.411 \\ 1.203 \\ 1.752 \\ 0.886 \\ 0.825 \end{bmatrix}$$

$$H_1 = \begin{bmatrix} 1.265 \\ 1.12 \\ 1.26 \\ 1.351 \\ 1.20 \\ 1.19 \end{bmatrix}$$

Computing H_2 :

$$Q_2 \times W_2 \Rightarrow \begin{bmatrix} 0.31 & 0.22 & 0.99 & 0.09 \\ 0.21 & 0.42 & 0.09 & 0.06 \\ 0.72 & 0.41 & 0.03 & 0.39 \\ 0.91 & 0.31 & 0.87 & 0.78 \\ 0.62 & 0.73 & 0.11 & 0.12 \\ 0.72 & 0.11 & 0.19 & 0.13 \end{bmatrix} * \begin{bmatrix} 0.3 \\ 0.8 \\ 0.9 \\ 0.6 \end{bmatrix}$$

$$\Rightarrow \begin{bmatrix} 1.184 \\ 0.516 \\ 1.048 \\ 1.652 \\ 0.941 \\ 0.52 \end{bmatrix} = K_2 = V_2$$

$$H_2 = \text{softmax} \left(\frac{Q_2 \cdot K_2^T}{\sqrt{d_k}} \right) \cdot V_2$$

$$= \begin{bmatrix} 1.184 \\ 0.516 \\ 1.048 \\ 1.652 \\ 0.941 \\ 0.52 \end{bmatrix} [1.184 \ 0.516 \ 1.048 \ 1.652 \ 0.941 \ 0.52]$$

$$= \begin{bmatrix} 1.40186 & 0.6109 & 1.24 & 1.955 & 1.114 & 0.615 \\ 0.61 & 0.266 & 0.54 & 0.85 & 0.48 & 0.26 \\ 1.24 & 0.54 & 0.098 & 1.73 & 0.98 & 0.54 \\ 1.065 & 0.85 & 1.73 & 2.729 & 1.55 & 0.85 \\ 1.11 & 0.48 & 0.98 & 1.555 & 0.88 & 0.48 \\ 0.61 & 0.268 & 0.54 & 0.85 & 0.489 & 0.2709 \end{bmatrix}$$

Applying softmax

$$\begin{bmatrix} 0.19 & 0.08 & 0.162 & 0.33 & 0.142 & 0.08 \\ 0.181 & 0.128 & 0.169 & 0.231 & 0.16 & 0.178 \\ 0.184 & 0.094 & 0.164 & 0.30 & 0.147 & 0.094 \\ 0.188 & 0.062 & 0.15 & 0.40 & 0.126 & 0.02 \\ 0.188 & 0.100 & 0.166 & 0.293 & 0.150 & 0.01 \\ 0.181 & 0.128 & 0.169 & 0.231 & 0.160 & 0.128 \end{bmatrix} \times \begin{bmatrix} 1.18 \\ 0.31 \\ 1.099 \\ 1.652 \\ 0.941 \\ 0.32 \end{bmatrix}$$

V_2

$$H_2 = \begin{bmatrix} 1.107 \\ 1.058 \\ 1.145 \\ 1.24 \\ 1.12 \\ 1.05 \end{bmatrix}$$

Computing for H_3

$$Q_3 \times W_3 = \begin{bmatrix} 0.31 & 0.22 & 0.94 & 0.04 \\ 0.21 & 0.49 & 0.09 & 0.06 \\ 0.71 & 0.41 & 0.37 & 0.39 \\ 0.31 & 0.31 & 0.87 & 0.78 \\ 0.67 & 0.74 & 0.11 & 0.12 \\ 0.72 & 0.11 & 0.14 & 0.13 \end{bmatrix} \times \begin{bmatrix} 0.8 \\ 0.3 \\ 0.6 \\ 0.9 \end{bmatrix} = \begin{bmatrix} 0.944 \\ 0.402 \\ 0.23 \\ 1.725 \\ 0.884 \\ 0.828 \end{bmatrix} = V_3 = k_3$$

$$H_3 = \text{Softmax}(Q_3 \cdot k_3^T) \cdot V_3$$

$$\Rightarrow \begin{bmatrix} 0.89 & 0.379 & 1.16 & 1.628 & 0.84 & 0.71832 \\ 0.37 & 0.1016 & 0.49 & 0.64 & 0.357 & 0.332 \\ 1.10 & 6.49 & 1.312 & 2.12 & 1.093 & 1.0184 \\ 1.62 & 0.64 & 2.121 & 2.07 & 1.533 & 1.428 \\ 0.03 & 0.35 & 1.093 & 1.53 & 0.790 & 1.0736 \\ 0.78 & 0.33 & 1.018 & 1.428 & 0.73 & 0.68 \end{bmatrix}$$

Applying softmax

$$\Rightarrow \begin{bmatrix} 0.14 & 0.08 & 0.191 & 0.303 & 0.138 & 0.13 \\ 0.16 & 0.124 & 0.181 & 0.219 & 0.157 & 0.15 \\ 0.13 & 0.064 & 0.193 & 0.355 & 0.127 & 0.11 \\ 0.116 & 0.04 & 0.1903 & 0.44 & 0.03 & 0.09 \\ 0.147 & 0.09 & 0.1406 & 0.24 & 0.14 & 0.133 \\ 0.144 & 0.095 & 0.1697 & 0.78 & 0.143 & 0.136 \end{bmatrix} \times \begin{bmatrix} 0.944 \\ 0.401 \\ 0.73 \\ 1.725 \\ 0.889 \\ 0.876 \end{bmatrix}$$

$$H_3 = \begin{bmatrix} 1.166 \\ 1.07 \\ 1.218 \\ 1.305 \\ 1.67 \\ 1.14 \end{bmatrix} \dots$$

Computing for H_4

$$a_4 \times w_4 \Rightarrow \begin{bmatrix} 0.31 & 0.72 & 0.44 & 0.04 \\ 0.31 & 0.42 & 0.04 & 0.06 \\ 0.72 & 0.41 & 0.03 & 0.34 \\ 0.51 & 0.31 & 0.87 & 0.78 \\ 0.67 & 0.73 & 0.11 & 0.12 \\ 0.72 & 0.71 & 0.14 & 0.15 \end{bmatrix} \times \begin{bmatrix} 0.6 \\ 0.3 \\ 0.9 \\ 0.8 \end{bmatrix} = \begin{bmatrix} 1.175 \\ 0.381 \\ 1.137 \\ 1.806 \\ 0.786 \\ 0.711 \end{bmatrix}$$

$$\Rightarrow \text{softmax}(Q_4 \times K_4^T) \cdot V_4$$

$$Q_4 \times K_4^T \Rightarrow \begin{bmatrix} 0.176 & 0.06 & 0.1684 & 0.37 & 0.11 & 0.1 \\ 0.176 & 0.129 & 0.173 & 0.12 & 0.15 & 0.14 \\ 0.177 & 0.67 & 0.169 & 0.3 & 0.11 & 0.1 \\ 0.1606 & 0.03 & 0.149 & 0.50 & 0.09 & 0.06 \\ 0.174 & 0.04 & 0.173 & 0.09 & 0.13 & 0.17 \\ 0.174 & 0.101 & 0.174 & 0.28 & 0.13 & 0.17 \end{bmatrix}$$

after softmax =

$$\text{Multiplying with } V_4 \text{ and we get } H_4 = \begin{bmatrix} 1.256 \\ 1.074 \\ 1.243 \\ 1.93 \\ 1.68 \\ 1.314 \end{bmatrix}$$

Now, computing multi-head attention

Multihead Attention $\text{concat}(H_1, H_2, H_3, H_4) \cdot W_0$

$$\begin{bmatrix} 1.126 & 1.167 & 1.1692 & 1.256 \\ 1.122 & 1.058 & 1.0707 & 1.074 \\ 1.126 & 1.2404 & 1.218 & 1.247 \\ 1.35 & 1.127 & 1.305 & 1.319 \\ 1.206 & 1.127 & 1.157 & 1.168 \\ 1.199 & 1.034 & 1.146 & 1.2914 \end{bmatrix} \times \begin{bmatrix} 1 & 1 & 1 & 1 \\ 0.5 & 0.5 & 0.5 & 0.5 \\ 0.7 & 0.7 & 0.7 & 0.7 \\ 0.3 & 0.3 & 0.3 & 0.3 \end{bmatrix}$$

$$\Rightarrow \begin{bmatrix} 3.04 & 3.0424 & 3.0424 & 3.0424 \\ 2.725 & 2.725 & 2.725 & 2.725 \\ 3.0606 & 3.0606 & 3.0606 & 3.0606 \\ 3.303 & 3.303 & 3.303 & 3.303 \\ 2.9304 & 2.9304 & 2.9304 & 2.9304 \\ 2.872 & 2.872 & 2.872 & 2.872 \end{bmatrix}$$

The resultant matrix is the multi head attention which we can ~~use~~ then pass to normalized layer and feed forward neural network and adding original embedding.
